

# 浙江大学

## 本科生毕业论文(设计)

### 文献综述和开题报告



姓名与学号 曾鹏熹 3180105152

指导教师 黄崇文

年级与专业 2018 级 信息工程

所在学院 信息与电子工程学院

# 目录

一、文献综述	3
1 简介 .....	3
2 信道估计理论 .....	3
3 基于深度学习的信道估计算法概述 .....	4
4 研究现存问题 .....	6
5 研究展望 .....	6
6 参考文献 .....	8
二、开题报告	9
1 问题背景 .....	9
1.1 通信系统与信道 .....	9
1.2 参考信号 .....	9
1.3 相关工作 .....	10
1.4 本研究的目的与意义 .....	11
2 研究主要内容与技术路线 .....	11
2.1 主要研究内容 .....	11
2.2 技术路线 .....	12
3 进度安排 .....	15
4 预期目标 .....	16
5 参考文献 .....	17
三、外文翻译	18
0. 摘要 .....	18
1. 引文 .....	18
2. 系统模型 .....	19
3. 基于 SF-CNN 的信道估计 .....	21
3.1. 算法描述 .....	21
3.2. 复杂度分析 .....	23
4. 基于 SFT-CNN 和 SPR-CNN 的信道估计 .....	25
4.1. 基于 SFT-CNN 的信道估计方法 .....	25
4.2. SFT-CNN 还是 LSTM-CNN? .....	27
4.3. 基于 SPR-CNN 的信道估计 .....	28
5. 数值结果 .....	31
6. 结论 .....	31
四、外文原文	32
毕业论文（设计）文献综述和开题报告考核	33

阻碍。为了能够提高通信系统的效率，我们需要尽可能消除不理想信道导致的信号扭曲，而这就需要对信道的特征进行描述，也就是信道估计。通常信道估计是通过比较已知信号在收发机两端的不同来获得大致的信道矩阵。整体过程为：首先在发射机端，我们发送一系列已知信号，即导频信号，这些导频信号通常经过一定的设计使其便于在接收端检测得到；随后这些信号通过信道被噪声扭曲；最后我们在接收机端收到相关信号，通过比较收发信号的差异，我们得到其相关关系，从而得到对信道的估计。

### 3 基于深度学习的信道估计算法概述

在机器学习中，根据训练方式大致可以分为有监督学习、无监督学习与强化学习。其中有监督学习被广泛应用于图像处理领域。在通信领域，对于基于深度学习的信道估计算法，我们不需要进行分类，而是需要获得数据的内在关系，拟合一定的算法，故一般视为无监督学习。

多数论文的深度学习架构基于经典深度学习结构，使用线性层或卷积层的连接来进行信道估计。在论文[5]中，作者提出了一种基于深度学习的信道估计算法，主要针对毫米波大规模 MIMO 系统。在该应用场景中，MIMO 系统的天线阵列数量巨大，而射频链路的数量却相对来说非常小，从而使得由收到的信号估计信道这项任务变得具有很大的挑战性。该论文针对该应用场景，提出了基于经典深度学习架构的 LDAMP (learned denoising-based approximate message passing) 网络，其中每一层均为相同的结构，通过多层连接，逐步学习得到信道估计。其中的去噪模块，论文使用了计算机视觉领域 (CV) 的相关工作 DnCNN (denoising convolutional neural network) [6] 来实现。DnCNN 的结构与经典卷积网络 VGG 类似，通过多层卷积层连接，但是最后其学习得到的是残差图像，即为噪声图像。作者通过仿真结果证明了 LDAMP 网络的优越性能，同时比较了 LDAMP 网络、SD 算法、SCAMP 算法以及 DAMP 算法，得出去噪模块的使用使得 LDAMP 网络和 DAMP 算法获得了性能上的提升。

在[7]中，研究团队针对毫米波大规模 MIMO 系统设计了基于与[5]相同的应用场景。论文逐步提出了三种架构，分别为空间-频率卷积网络 (SF-CNN)、空间-频率-时间卷积网络 (SFT-CNN) 和空间导频减少卷积网络 (SPR-CNN)，其中

模型驱动 DL 的一个特例。CsiNet 主要包括一个卷积神经网络（CNN），该网络成功地进行了图像处理，并采用了一种自动编码器架构，该架构包括一个用于压缩感知的编码器和一个用于重建的解码器。每个细化网络单元遵循残余网络的思想，即它将较浅层的输出传输到较深层的输入，以避免 DNN 中的梯度消失问题。但该网络及其改进网络 CsiNet-LSTM[13] 不适用于实际的时变信道，因为线性全连接网络不适合描述时间相关性。另外该设计也未考虑天线的空间相关性。对于信道估计这一问题，数学模型难以精确建模描述信道的时域相关性与频域相关性，从而使得基于模型驱动的深度神经网络容易忽略数据的相关关系，进而限制模型的性能。

## 4 研究现存问题

目前已有的基于深度学习的信道估计算法已经有对于 MIMO 系统的信道有良好的性能表现，但是仍然存在部分问题。例如基于导频估计信道的多种深度学习算法，由于需要从少量时频信道值获得整个时频域的信道值，首先需要使用诸如插值等手段重建高精度信道矩阵，在重建过程中会将噪声扩散至其他时频位置，而非线性插值会使得扩散后的噪声非高斯白噪声，从而导致用于处理高斯白噪声的深度卷积网络表现不佳。另外，现有网络存在不够精细的缺点，虽然在信噪比较低的情况下能够取得明显优于传统算法的特点，但是当信噪比较高时，性能出现了一定的退化。传统深度学习，如 DNN 或 CNN，存在一定的精细度的限制，为了提高深度学习在这些情形下对信道的估计能力，需要完成进一步的研究，采用新的结构或者设计更加有效的网络架构。最后，部分设计忽视了实际通信信道中的时间相关性或者频率相关性，难以应用至现实信道。

## 5 研究展望

近年，深度学习在 CV 以及自然语言处理（NLP）领域取得了引人瞩目的发展。在自然语言处理领域提出了具有重要意义的 Transformer 模型[14]，该模型弥合了 CV 与 NLP 之间的模型差异，且具有应用至多个领域的潜力，目前已有相关尝试[15]。该模型可以观察到两个维度的信息，如时间的相关性和特征的相关性，在信道估计中可以用于建模时频两个维度的相关性。在 5G 时代，信道

## 6 参考文献

- [1]: D. Neumann, T. Wiese, and W. Utschick, "Learning the MMSE channel estimator," *IEEE Trans. on Signal Process.*, vol. 66, no. 11, pp. 2905–2917, 2018.
- [2]: Z. Du, X. Song, J. Cheng, and N. C. Beaulieu, "Maximum likelihood based channel estimation for macrocellular OFDM uplinks in dispersive time-varying channels," *IEEE Trans. on Wireless Commun.*, vol. 10, no. 1, pp. 176–187, 2011.
- [3]: C. Jiang, H. Zhang, Y. Ren, Z. Han, K.-C. Chen, and L. Hanzo, "Machine learning paradigms for next-generation wireless networks," *IEEE Wireless Commun.*, vol. 24, no. 2, pp. 98–105, 2017.
- [4]: Er, M.J., Zhou, Y.: *Theory and novel applications of machine learning*. InTech, 2009.
- [5]: H. He, C.-K. Wen, S. Jin, and G. Y. Li, "Deep learning-based channel estimation for beamspace mmWave massive MIMO systems," *IEEE Wireless Commun. Lett.*, vol. 7, no. 5, pp. 852–855, 2018.
- [6]: K. Zhang, W. Zuo, Y. Chen, D. Meng, and L. Zhang, "Beyond a Gaussian denoiser: Residual learning of deep CNN for image denoising," *IEEE Trans. Image Process.*, vol. 26, no. 7, pp. 3142–3155, 2017.
- [7]: P. Dong, H. Zhang, G. Y. Li, I. S. Gaspar, and N. NaderiAlizadeh, "Deep CNN-based channel estimation for mmWave massive MIMO systems," *IEEE J. Sel. Topics in Signal Process.*, vol. 13, no. 5, pp. 989–1000, 2019.
- [8]: C.-J. Chun, J.-M. Kang, and I.-M. Kim, "Deep learning-based joint pilot design and channel estimation for multiuser MIMO channels," *IEEE Commun. Lett.*, vol. 23, no. 11, pp. 1999–2003, 2019.
- [9]: Y. Yang, F. Gao, X. Ma, and S. Zhang, "Deep learning-based channel estimation for doubly selective fading channels," *IEEE Access*, vol. 7, pp. 36 579–36 589, 2019.
- [10]: M. Soltani, V. Pourahmadi, A. Mirzaei, and H. Sheikhzadeh, "Deep learning-based channel estimation," *IEEE Commun. Lett.*, vol. 23, no. 4, pp. 652–655, 2019.
- [11]: C. Dong, C. C. Loy, K. He, and X. Tang, "Image super-resolution using deep convolutional networks," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 38, no. 2, pp. 295–307, 2016.
- [12]: C. K. Wen, W. T. Shih, and S. Jin, "Deep Learning for Massive MIMO CSI Feedback," *IEEE Wireless Commun. Lett.*, vol. 7, no. 5, 2018, pp. 748–51.
- [13]: T. Wang, C. Wen, S. Jin, G. Y. Li, "Deep Learning-Based CSI Feedback Approach for Time-Varying Massive MIMO Channels," *IEEE Wireless Commun. Lett.*, Vol. 8, no. 2, pp. 416-419, 2019.
- [14]: Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *NeurIPS*, 2017.
- [15]: Y. Xu, M. Yuan, and M.-O. Pun, "Transformer empowered CSI feedback for massive MIMO systems," in *Wireless and Optical Commun. Conf.*, Taipei, Taiwan, Oct. 2021, pp. 157–161.

(Demodulation Reference Signal, DMRS) 进行估计以及相关解调。解调参考信号在时频平面上占有少量的位置, 并随数据信号在发射机发送。接收机知道解调参考信号的时频位置 and 值。在接收端, 通过比较发送和接收的解调参考信号, 得到解调参考信号子信道矩阵。解调参考信号信道估计的目的是基于解调参考信号子信道矩阵得到各时频位置的信道响应, 并恢复全信道矩阵。由于解调参考信号的密度较低、且由于 5G 的应用需要面对高动态的应用场景, 单个符号内的信道变化可能会越来越严重, 传统的线性恢复算法, 如维纳滤波等, 在实际部署时仍然有效但不是最优算法。为了提高信道估计的精度与准确性, 以及提高信道估计过程中, 系统对噪声的抑制能力, 我们需要设计更加有效的算法。深度学习是一个复杂的机器学习算法, 在语音和图像识别方面取得的效果, 远远超过先前相关技术。与传统方法相比, 基于深度学习的技术的优点之一是其鲁棒性。尤其是当数据量较大时, 深度学习具有优于传统方法的描述数据特征的良好表征能力。

### 1.3 相关工作

最近几年内, 深度学习在多个领域取得重大突破, 在通信领域也得到了广泛关注。其优秀的非线性拟合能力以及学习能力使其能够从数据中学习得到一定的规律, 获得比传统方法更优异的性能, 如准确性、鲁棒性。在通信领域已有多个课题运用深度学习, 包括信道估计、信号检测、编码与解码等。在数据传输速率与带宽不断增大的发展趋势下, 深度学习具有良好的应用前景。对于本研究题目, 即基于深度学习的信道估计, 已有论文进行讨论。如[1][2]和[3]针对大型 MIMO 多用户系统提出了基于经典深度学习的结构, 即线性层或卷积层的组合, 提出了包括 LDAMP[1]、SFT-CNN[2] 等深度学习结构, 取得了大幅优于超过经典算法, 如 LMMSE (线性最小均方)、EM (最大期望) [4][5]的效果。同时如 SPR-CNN[2] 等结构有助于压缩导频长度, 节约宝贵的频谱资源。随着深度学习在图像处理领域的飞速发展, 部分研究尝试将信道时频矩阵通过图像处理的方式进行估计[6]。部分研究尝试将专家知识嵌入深度学习结构, 提出了基于理论模型的深度学习结构[1][7][8]。随着深度学习的发展, 部分研究也在更新用于信道估计的深度学习结构[9]。

存在相关性，时域也同样存在相关性。需要充分利用该相关性以获得良好的预测性能。对于每个信道样本，信道相关参数均为随机生成，如时延扩展、用户移动速度、信噪比等，其中仅有信噪比已知。




图 1 DMRS 时频矩阵样例

## 2.2 技术路线

### 2.2.1 基础模型

深度学习近年来在自然语言处理（NLP）以及计算机视觉（CV）取得了引人注目的成就。在 2017 年提出的 Transformer 模型[9]，其结构如图 2 所示。该基础模型由两个部分组成，图中左半部分的编码器（Encoder）与图中右半部分的解码器（Decoder）。其基本工作机制如下：在 Encoder 中，通过 Multi-Head Attention（多头注意力）模块建立时间维度的相关关系，将不同时间（第一个维度）的特征（第二个维度）联系起来，并且该模块强迫该模型对不同时刻的特征赋予不同比例的“注意力”。考虑到信道的特点，该模块有助于时频图像的恢复。Feed Forward 模块则进一步提取特征信息。在 Decoder 中，大部分模块与 Encoder 相同或类似，而 Masked Multi-Head Attention 模块通过遮盖当前时刻之后的信息，使得训练的行为方式与预测的行为方式一致。而 Positional Encoding 用于加载前后关系的信息。Transformer 在 NLP 问题上取得了显著的效果，并且其优秀的可移植性使得 CV 等领域也有大量相关工作利用 Transformer 提取图片中的语义信息，并进行如分类、语义分割、图像重建等任

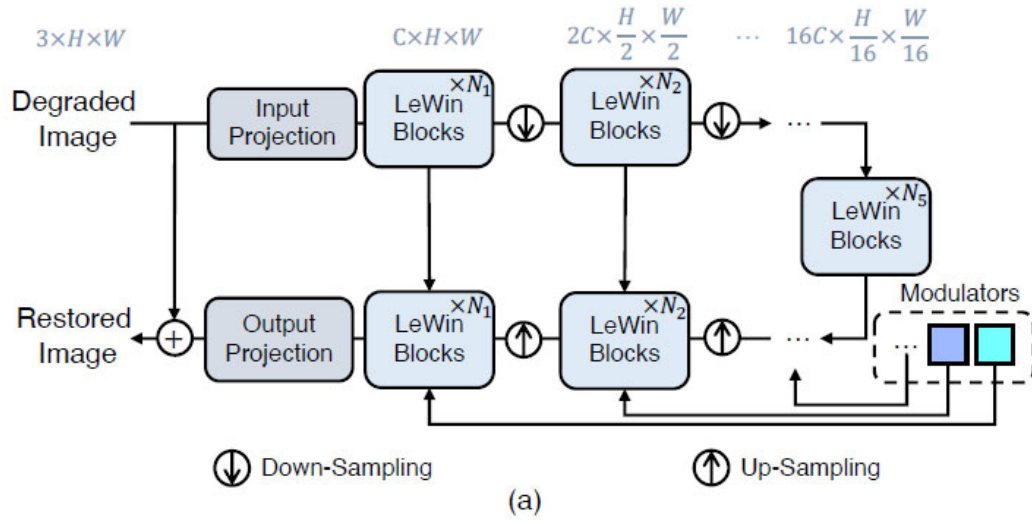


图 3 Uformer 基本结构

对于重建模型，Transformer 同样也取得了引人注目的成绩。最近 FAIR 团队一篇论文提出了 Masked Autoencoders (MAE) [11]，能够从被大范围遮盖的残留图像恢复原始图像语义。如图 4 中结构，MAE 以未遮掩图像作为输入，经过 Encoder 编码提取语义信息，随后输入 Decoder 进行图像重建，其中 Encoder 和 Decoder 均由 Transformer 构成，最终能有效恢复图像。该模型在多个数据集上取得了 SOTA 结果。




图 4 MAE 总体结构

综上，利用 Transformer 能够有效完成去噪与重建的工作，且有大量工作作为借鉴，为迁移学习提供帮助。



## 4 预期目标

- 1、复现基于经典深度学习的信道估计算法。
- 2、基于 Transformer 设计新的深度学习结构，取得优于经典深度学习的效果。

### 三、外文翻译

#### 0. 摘要

对于毫米波（mmWave）大规模多输入多输出（MIMO）系统，通常使用混合处理架构来降低复杂性和成本，这在信道估计中提出了非常具有挑战性的问题。本文采用深度卷积神经网络（CNN）来解决这个问题。我们首先提出了一种利用空间和频率相关性的基于空间频率 CNN（SF-CNN）的信道估计，其中相邻子载波处的损坏信道矩阵被同时输入到 CNN 中。然后，利用时变信道中的时间相关性，开发了基于空间频率-时间 CNN（SFT-CNN）的方法以进一步提高准确性。此外，我们设计了一种空间导频减少 CNN（SPR-CNN）以节省信道估计的空间导频开销，其中几个连续相干间隔中的信道被具有存储器的信道估计单元分组和估计。数值结果表明，所提出的基于 SF-CNN 和 SFT-CNN 的方法优于非理想最小均方误差（MMSE）估计器，且复杂度降低，而且性能接近难以实际部署的理想 MMSE 估计器。它们对不同的传播场景也很有效。基于 SPR-CNN 的方法达到了与基于 SF-CNN 和 SFT-CNN 的方法相当的性能，同时仅以复杂为代价仅需要约三分之一的导频开销。本文的结果清楚地表明，深卷积网络可以有效地利用信道相关性，以提高 mmWave 大规模 MIMO 系统的估计性能。

#### 1. 引文

略

传统的信道估计方法在实际情况较复杂的信道模型中往往表现不佳，而且复杂度高。相比之下，深度卷积神经网络(deep convolutional NN, CNN)更能从大量的数据中提取出隐藏在信道矩阵下的固有特征，并通过高效的并行计算方法提供了以更低的复杂度更准确地估计信道的潜力。在本文中，我们使用深度 CNN 来解决 mmWave 大规模 MIMO-OFDM 系统的信道估计问题。为了利用 OFDM 中相邻子载波上信道之间的相关性，我们首先提出了一种基于空间频率 CNN（SF-CNN）的信道估计方法，其中在相邻子载波上初步估计的信道矩阵同时输入到 CNN [1] 中。为了进一步利用时间相关性，提出了一种基于空间-频率-时间 CNN（SFT-CNN）的

达与离开时的方位角（AoA/AoD）。对于均匀线阵（ULA），对应的响应向量可以表示为：

$$\mathbf{a}_R(\phi_l) = \frac{1}{\sqrt{N_R}} \left[ 1, e^{-j2\pi\frac{d}{\lambda}\sin(\phi_l)}, \dots, e^{-j2\pi\frac{d}{\lambda}(N_R-1)\sin(\phi_l)} \right]^T,$$

$$\mathbf{a}_T(\phi_l) = \frac{1}{\sqrt{N_T}} \left[ 1, e^{-j2\pi\frac{d}{\lambda}\sin(\phi_l)}, \dots, e^{-j2\pi\frac{d}{\lambda}(N_T-1)\sin(\phi_l)} \right]^T,$$

其中 $d$ 和 $\lambda$ 分别表示相邻天线之间的距离与载波波长。

根据(1)中的信道模型，给出 OFDM 中第  $k$  个子载波的频域信道为

$$\mathbf{H}_k = \sqrt{\frac{N_T N_R}{L}} \sum_{l=1}^L \alpha_l e^{-j2\pi\tau_l f_s \frac{k}{K}} \mathbf{a}_R(\phi_l) \mathbf{a}_T^H(\phi_l),$$

其中  $f_s$  为采样率， $K$  为 OFDM 子载波数。

为了估计 $\mathbf{H}_k$ ，发射机仅激活一个射频链以在每个信道使用的一个波束上发射导频，而接收机通过使用与不同波束相关联的所有射频链来组合接收的导频。更详细地说，发射机使用 $M_T$ 个波束形成向量， $\mathbf{f}_{k,u} \in \mathbb{C}^{N_T \times 1}$ ,  $u = 1, \dots, M_T$  传输导频 $x_{k,u}$ 。对于每个波束形成向量 $\mathbf{f}_{k,u}$ 对应的发射导频信号，接收机采用 $M_R$ 个组合向量， $\mathbf{w}_{k,v} \in \mathbb{C}^{N_R \times 1}$ ,  $v = 1, \dots, M_R$ ，分别对其进行处理。由于接收器配备了 $N_R^{RF} (< M_R)$ 条射频链，它只能在一个信道使用中使用 $N_R^{RF}$ 个组合矢量。然后，如果接收端使用所有 $M_R$ 个向量来处理一个携带导频的波束形成向量，则需要使用的信道数量为 $\left\lceil \frac{M_R}{N_R^{RF}} \right\rceil$ 。则与接收机基带第  $k$  个子载波相关联的导频信号矩阵可写成

$$\mathbf{Y}_k = \mathbf{W}_k^H \mathbf{H}_k \mathbf{F}_k \mathbf{X}_k + \tilde{\mathbf{N}}_k,$$

其中 $\mathbf{W}_k = [\mathbf{w}_{k,1}, \dots, \mathbf{w}_{k,M_R}]$ 和 $\mathbf{F}_k = [\mathbf{f}_{k,1}, \dots, \mathbf{f}_{k,M_T}]$ 分别是结合矩阵和波束形成矩阵， $\mathbf{X}_k$ 是 $M_T \times M_T$ 的对角阵其第  $u$  个元素为 $x_{k,u}$ 。 $\tilde{\mathbf{N}}_k = \mathbf{W}_k^H \mathbf{N}_k$ 表示合并后的有效噪声， $\mathbf{N}_k$ 为合并前元素参数为 $\mathcal{CN}(\mu, \sigma^2)$ 的加性高斯白噪声（AWGN）。

我们在频域和时域都考虑导频插入。具体而言，相邻 $Q(Q \geq 2)$ 个子载波分别

<sup>1</sup> 这个导频传输过程可以捕获毫米波通道中的主要路径。虽然在发射机同时激活多个具有不同波束的射频链可以加速导频传输过程，但无法捕获主路径，导致信道估计性能较差。因此，在大量的相关工作中，在每个信道使用过程中，发射机的一个波束上只激活一个射频链来传输导频，以保证信道估计算法[9]、[11]的性能。同样，在本文中，我们考虑的导频传输模式也有助于基于 CNN 的信道估计达到很好的精度。

$$\mathbf{G}_L = \begin{cases} \mathbf{W}^H, & M_R < N_R \\ (\mathbf{W}\mathbf{W}^H)^{-1}\mathbf{W}, & M_R \geq N_R \end{cases}$$

且

$$\mathbf{G}_R = \begin{cases} \mathbf{F}^H, & M_T < N_T \\ \mathbf{F}^H(\mathbf{F}\mathbf{F}^H)^{-1}, & M_T \geq N_T \end{cases}$$

然后将初步估计的信道矩阵 $\mathbf{R}_{k_0}$ 和 $\mathbf{R}_{k_0+1}$ 同时输入到 SF-CNN 中, SF-CNN 通过映射关系输出估计的信道矩阵 $\hat{\mathbf{H}}_{k_0}$ 和 $\hat{\mathbf{H}}_{k_0+1}$

$$\{\hat{\mathbf{H}}_{k_0}, \hat{\mathbf{H}}_{k_0+1}\} = f_{\Phi}(\mathbf{R}_{k_0}, \mathbf{R}_{k_0+1}; \Phi), \quad (10)$$

其中 $\Phi$ 代表 SF-CNN 的参数集合。

2) SF-CNN 离线训练: 对于提出的 SF-CNN, 在仿真环境中根据一定的信道模型生成由 $N_{tr}$ 个样例组成的训练集, 其中 $(\mathbf{R}_i, \mathbf{H}_i)$ 表示第  $i$  个样本, 其中 $\mathbf{R}_i$ 为输入数据,  $\mathbf{H}_i$ 为目标数据。 $\mathbf{R}_i \in \mathbb{C}^{N_R \times N_T \times 2}$ 是由 $\mathbf{R}_{k'_0}^i, \mathbf{R}_{k'_0+1}^i \in \mathbb{C}^{N_R \times N_T}$ 组成的三维矩阵, 分别为子载波 $k'_0$ 和 $k'_0+1$ ,  $k'_0 \in \{1, 2, \dots, K-1\}$ 。 $\mathbf{H}_i \in \mathbb{C}^{N_R \times N_T \times 2}$ 也是一个三维矩阵, 含 $\frac{\mathbf{H}_{k'_0}^i}{c}, \frac{\mathbf{H}_{k'_0+1}^i}{c} \in \mathbb{C}^{N_R \times N_T}$ , 其中 $\mathbf{H}_{k'_0}^i$ 和 $\mathbf{H}_{k'_0+1}^i$ 是对应的真实信道矩阵。 $c > 0$ 是一个缩放常数, 使得所有目标数据 $\mathbf{H}_i$ 的实部和虚部的取值范围匹配 SF-CNN 输出层应用的激活函数。然后 $\mathbf{R}_i$ 输入 SF-CNN 来近似对应的缩放真实信道值 $\mathbf{H}_i$ 。

对于 mmWave 大规模 MIMO 系统, 以 $N_T = 32$ ,  $N_R = 16$ 为例。如图 1 所示, SF-CNN 接收到初步估计的复信道矩阵 $\mathbf{R}_{k'_0}^i \in \mathbb{C}^{16 \times 32}$ 和 $\mathbf{R}_{k'_0+1}^i \in \mathbb{C}^{16 \times 32}$ , 作为输入, 并将其实部和虚部分开, 从而得到 4 个  $16 \times 32$  实值矩阵。在随后的卷积层中, 这四个矩阵通过 64 个  $3 \times 3 \times 4$  卷积滤波器和修正线性单元 (ReLU) 激活函数进行处理, 生成 64 个  $16 \times 32$  的实值矩阵。在处理每个特征矩阵时使用零填充 (Zero padding, ZP), 使其卷积后维数保持不变。然后加入批归一化 (batch normalization, BN) 层, 以避免梯度扩散和过拟合。对于接下来的八个卷积层, 每个层使用 64 个  $3 \times 3 \times 64$  滤波器对前一层传递的特征矩阵进行 ZP 卷积, 并输出 64 个  $16 \times 32$  实值特征矩阵。对这 8 个层应用 ReLU 激活函数, 每个层后面都有一个 BN 层。输出层使用 4 个  $3 \times 3 \times 64$  卷积滤波器来处理 64 个  $16 \times 32$  实值特征矩阵, 并得到在 $k'_0$ 和 $k'_0+1$ 处子载波的缩放信道矩阵估计值, 即

算复杂度，并将其与使用估计协方差矩阵的非理想 MMSE 进行比较。所需的浮点操作数 (FLOPs) 被用作度量标准。

TABLE II  
SF-CNN PARAMETER SETTINGS

$l$	$M_{1,l}$	$M_{2,l}$	$F_l$	$N_{l-1}$	$N_l$
1	16	32	3	4	64
2 ~ 9	16	32	3	64	64
10	16	32	3	64	4

对于所提出的方法，FLOPs 来自于 (7) 和 SF-CNN 中的 TE 模块处理。通过假设  $M_T = N_T$  和  $M_R = N_R$ ，(7) 中的矩阵乘积需要  $C_{TE} \sim \mathcal{O}(QN_T N_R (N_T + N_R))$  [24] 次 FLOPs。根据 [25]，SF-CNN 处理所需的 FLOPs 为  $C_{SF-CNN} \sim \mathcal{O}(\sum_{l=1}^{L_c} M_{1,l} M_{2,l} F_l^2 N_{l-1} N_l)$ ，其中  $L_c$  为卷积层数， $M_{1,l}$  与  $M_{2,l}$  表示第  $l$  层输出的每个特征图的行数和列数， $F_l$  表示第  $l$  层使用的滤波器的边长， $N_{l-1}$  和  $N_l$  表示第  $l$  层输入和输出特征图的个数。具体来说，这些参数根据上述 SF-CNN 离线训练列在表 II 中。然后基于 SF-CNN 信道估计的计算复杂度如下

$$C_{SF-CNN-CE} \sim \mathcal{O}\left(QN_T N_R (N_T + N_R) + N_T N_R \sum_{l=1}^{L_c} F_l^2 N_{l-1} N_l\right), \quad (12)$$

对于 MMSE 信道估计，首先需要进行最小二乘 (LS) 信道估计，从而导致  $C_{LS} \sim \mathcal{O}(QN_T^2 N_R^2)$  的 FLOPs。然后，基于每通道实现一次的 LS 信道估计计算信道协方差矩阵，如果考虑空间和频率信道统计，则需要  $C_{MMSE,1} \sim \mathcal{O}(Q^2 N_T^2 N_R^2)$  的计算复杂度。最后，利用协方差矩阵对 LS 信道估计进行细化，相应的 FLOPs 为  $C_{MMSE,2} \sim \mathcal{O}(Q^3 N_T^3 N_R^3)$ 。因此，MMSE 的总体计算复杂度为

$$C_{MMSE} \sim \mathcal{O}(Q^3 N_T^3 N_R^3) \quad (13)$$

一般来说，很难直接比较  $C_{SF-CNN-CE}$  与  $C_{MMSE}$ ，因为前者除了  $Q$ ， $N_T$  和  $N_R$  以外依赖于  $L_c$ 、 $F_l$ 、 $N_{l-1}$  和  $N_l$ 。如果  $N_T = 32$ ， $N_R = 16$ ， $Q = 2$  等 SF-CNN 的参数列在表 II 中，所提出的基于 SF-CNN 方法的计算复杂度在  $10^8$  数量级，而 MMSE 需要更高的复杂度在  $10^9$  数量级。此外，使用 NVIDIA GeForce GTX 1080 Ti GPU，SF-CNN 能够以更高效的并行方式运行，对于一个信道的预测的运行时间仅为  $1.47 \times 10^{-4}$  秒。相比之下，MMSE 在 Intel(R) Core(TM) i7-3770 CPU 上单信道预测消耗大约  $6.14 \times 10^{-2}$  秒的时间。

类似于基于 SF-CNN 的信道估计， $\mathbf{Y}_k[n]$ 随后由 TE 模块进行处理，生成初步估计的信道矩阵，依次为

$$\mathbf{R}_k[n] = \sqrt{P}\mathbf{G}_L\mathbf{W}^H\mathbf{H}_k[n]\mathbf{F}\mathbf{G}_R + \mathbf{G}_L\tilde{\mathbf{N}}_k[n]\mathbf{G}_R \quad (17)$$

然后，SFT-CNN 通过同时利用信道的空间、频率和时间相关性进一步细化这些初步估计的信道矩阵。如图 2 所示，我们捕捉 $S(= 2)$ 连续相干间隔 $n_0$ 和 $(n_0 + 1)$ 来描述信道估计过程。在第 $n_0$ 个相干区间内，将初步估计的信道矩阵 $\mathbf{R}_{k_0}[n_0]$ 和 $\mathbf{R}_{k_0+1}[n_0]$ 输入 SFT-CNN。 $\mathbf{R}_{k_0}[n_0]$ 和 $\mathbf{R}_{k_0+1}[n_0]$ 的副本存储在缓存中，以便在下一个相干间隔中使用。在第 $(n_0 + 1)$ 相干区间内，SFT-CNN 接收初步估计的信道矩阵 $\mathbf{R}_{k_0}[n_0 + 1]$ 和 $\mathbf{R}_{k_0+1}[n_0 + 1]$ ，然后从缓存中取 $\mathbf{R}_{k_0}[n_0]$ 和 $\mathbf{R}_{k_0+1}[n_0]$ 进行联合处理，得到估计的信道矩阵为

$$\begin{aligned} & \{\hat{\mathbf{H}}_{k_0}[n_0 + 1], \hat{\mathbf{H}}_{k_0+1}[n_0 + 1]\} \\ & = f_{\Psi}(\mathbf{R}_{k_0}[n_0], \mathbf{R}_{k_0+1}[n_0], \mathbf{R}_{k_0}[n_0 + 1], \mathbf{R}_{k_0+1}[n_0 + 1]; \Psi) \end{aligned} \quad (18)$$

其中 $\Psi$ 表示 SFT-CNN 的参数集。同时，通过将 $\mathbf{R}_{k_0}[n_0]$ 和 $\mathbf{R}_{k_0+1}[n_0]$ 替换为 $\mathbf{R}_{k_0}[n_0 + 1]$ 和 $\mathbf{R}_{k_0+1}[n_0 + 1]$ 从而更新缓存。在每个相干间隔中，使用相同的 SFT-CNN，因为它学习了一般的信道时间相关性，而不是两个连续相干间隔中信道之间的具体关系。

在总结了频道估计过程之后，我们着重介绍了 SFT-CNN 的离线训练。与 SFCNN 类似，在仿真环境中根据一定的信道模型生成由 $N_{tr}$ 个样例组成的训练集，

$(\mathbf{R}_i, \mathbf{H}_i)$ 表示第  $i$  个样本。 $\mathbf{R}_i \in \mathbb{C}^{N_R \times N_T \times 4}$ 是三维矩阵，包含了在第 $n'_0$ 和第 $n'_0 + 1$ 相干间隔内由 (17) 获得的初步估计信道矩阵，即为  $\mathbf{R}_i =$

$\left[ \mathbf{R}_{k'_0}^i[n'_0], \mathbf{R}_{k'_0+1}^i[n'_0], \mathbf{R}_{k'_0}^i[n'_0 + 1], \mathbf{R}_{k'_0+1}^i[n'_0 + 1] \right], n'_0 \in \mathbb{N}_+$ 。 $\mathbf{H}_i \in \mathbb{C}^{N_R \times N_T \times 2}$ 也是

在第 $n'_0 + 1$ 相干间隔内一个由缩放后的真实信道矩阵组成的，即  $\mathbf{H}_i =$

$\left[ \frac{\mathbf{H}_{k'_0}^i[n'_0+1]}{c}, \frac{\mathbf{H}_{k'_0+1}^i[n'_0+1]}{c} \right]$ 。与前面一样， $c > 0$ 是缩放常数，使所有目标数据， $\mathbf{H}_i$ ，

的实部和虚部的取值范围与 SFT-CNN 输出层中应用的激活函数相匹配。然后将 $\mathbf{R}_i$

输入 SFT-CNN，逼近相应的缩放真信道 $\mathbf{H}_i$ 。SFT-CNN 的结构类似于 SF-CNN，除了

SFT-CNN 和 LSTM-CNN 在整个信噪比 (SNR) 范围内取得了几乎相同的性能。




Fig. 3. NMSE for SFT-CNN and LSTM-CNN based channel estimation.

3) **训练和测试复杂性**: 在相同的 NMSE 性能下, 复杂性成为方法选择的一个重要指标。表 4 给出了 SFT-CNN 和 LSTM-CNN 在 NVIDIA GeForce GTX 1080 Ti GPU 上训练和测试的时间复杂度, 其中  $N_c$  表示 CNN 所涉及的相干间隔数。很明显, LSTM-CNN 在训练和测试阶段都比 SFT-CNN 花费更多的时间。

TABLE IV  
TIME COMPLEXITY OF TRAINING AND TESTING

	Training time seconds/epoch		Testing time seconds/channel realization	
	$N_c = 2$	$N_c = 4$	$N_c = 2$	$N_c = 4$
SFT-CNN	22	23	$1.51 \times 10^{-4}$	$1.7 \times 10^{-4}$
LSTM-CNN	34	48	$3.53 \times 10^{-4}$	$5.14 \times 10^{-4}$

### 4.3. 基于 SPR-CNN 的信道估计

发射端和接收端的大规模阵列天线在空间域上产生巨大的导频开销。在这个小节, 我们设计了基于 SPR-CNN 的信道估计, 使用较少的导频, 但仍然保证了较好的准确性。

基于 SPR-CNN 的信道估计的基本思想可以总结如下:

- 1) 将  $D$  个连续相干间隔分组作为 CEU, 利用信道相关性降低空间导频开销。不同 CEU 不重叠。
- 2) 在每个 CEU 的第一个相干区间内, 使用全空间导频开销进行信道估计。<sup>2</sup> 然后在随后的相干间隔内减小导频开销。
- 3) 对于第一个相干间隔, 接收端使用当前接收的导频估计当前信道。对于其余的相干间隔, 接收器使用当前和之前在该 CEU 中接收到的所有导频来联合估计当前信道。

<sup>2</sup> 全空间导频开销是指波束形成向量的数量等于发射天线的数量, 组合向量的数量等于接收天线的数量。

$\mathbf{R}_{k_0}[n_0]$ 和 $\mathbf{R}_{k_0+1}[n_0]$ 的副本，为后续相干间隔的信道估计提供额外的信道信息。在 $(n_0 + 1)$ 相干区间内，为了节省导频开销，将 $\mathbf{F}[n]$ 和 $\mathbf{W}[n]$ 的维度减小，即 $M_T[n] < N_T$ 和 $M_R[n] < N_R$ 。<sup>3</sup>  $\mathbf{R}_{k_0}[n_0]$ 和 $\mathbf{R}_{k_0+1}[n_0]$ 以及 $\mathbf{R}_{k_0}[n_0 + 1]$ 和 $\mathbf{R}_{k_0+1}[n_0 + 1]$ 同时输入到 SPR-CNN-2 中，得到 $\hat{\mathbf{H}}_{k_0}[n_0 + 1]$ 和 $\hat{\mathbf{H}}_{k_0+1}[n_0 + 1]$ 。除了 $\mathbf{R}_{k_0}[n_0]$ 和 $\mathbf{R}_{k_0+1}[n_0]$ 外，缓存中还存储了 $\mathbf{R}_{k_0}[n_0 + 1]$ 和 $\mathbf{R}_{k_0+1}[n_0 + 1]$ 。利用缓存中存储的所有矩阵对第 $(n_0 + 2)$ 个相干区间进行联合信道估计。 $(n_0 + 2)$ 和 $(n_0 + 3)$ 相干区间的信道估计与 $(n_0 + 1)$ 相干区间的信道估计相似。在第 $(n_0 + 3)$ 相干区间内进行信道估计后，缓存将被清空，然后用于下一个 CEU。从图 4 中，四个不同的 SPR-CNN 分别用于 CEU 的相干间隔，并在所有 CEU 中重用。SPR-CNN 的结构和训练过程与 SFT-CNN 相似，只是不同 SPR-CNN 的输入矩阵数量不同。算法 1 给出了基于 SPR-CNN 的信道估计的直观描述。

在 4 个 SPR-CNN 中，SPR-CNN-4 的复杂度最高，输入矩阵最多。但与第三节的 SF-CNN 相比，它只是增加了第一卷积层 $D(= 4)$ 倍的复杂度，对总计算复杂度的影响有限。因此，基于 SPR-CNN 的信道估计在适度增加复杂度的同时，有效地节省了空间导频开销。

我们设计了基于 SPR-CNN 的信道估计，目的是在显著降低空间域导频开销的同时，仍然保证较好的信道估计精度。在每个有 $D$ 个相干间隔的 CEU 中，在第一个相干间隔中使用完整的导频开销，而在其余的相干间隔中使用减少的导频开销。第一个相干区间提供了完整的信道信息，这对该 CEU 中所有相干区间的信道估计很有帮助。很明显，CEU 的平均导频开销随着 $D$ 的增加而减少。但是，增加 $D$ 也会降低平均信道估计精度，因为第一个相干区间提供的完整信道信息的影响随着时间相关性的消失而减弱。因此，我们的 SPR-CNN 架构在一个 CEU 中包含了四个相干间隔，以在导频开销和估计精度之间实现良好的权衡。另外，如果使用 LSTM-CNN 进行图 4 中的信道估计，则需要 4 个结构如表 3 所示的 LSTM-CNN。如第四-2 节所述，LSTM-CNN 在性能上并不优于简单的 SFT-CNN 架构，但其复杂性要高得多，不适合基于 SPR-CNN 的信道估计。

<sup>3</sup> 在一个 CEU 的不同相干间隔中可以使用不同的导频开销。但是对于每个相干间隔，它和它在其他 CEU 中的对应部分应该使用相同的导频开销。



## 四、外文原文